

Sistema inteligente para la detección de correos electrónicos maliciosos mediante técnicas de Inteligencia Artificial

Planteamiento del problema

El correo electrónico es una de las herramientas de comunicación más utilizadas actualmente en ámbitos personales, académicos y laborales. A través de este medio se intercambia información, documentos, notificaciones y datos importantes de manera rápida. Sin embargo, esta popularidad también ha provocado que sea utilizado como un medio para realizar ataques informáticos dirigidos a los usuarios.

Uno de los principales riesgos es la recepción de correos electrónicos maliciosos, especialmente aquellos relacionados con técnicas como el *phishing*. Este tipo de mensajes busca engañar al usuario haciéndose pasar por una persona, empresa o institución legítima con el propósito de obtener información confidencial, como contraseñas, datos personales o información financiera. También pueden intentar dirigir al usuario hacia páginas fraudulentas o convencerlo de descargar archivos potencialmente peligrosos.

Aunque existen características que permiten reconocer algunos de estos mensajes, como direcciones de remitentes sospechosas, enlaces desconocidos, solicitudes urgentes, errores en el texto o intentos de generar miedo, no todos los usuarios cuentan con los conocimientos necesarios para identificarlos. Además, los mensajes fraudulentos pueden presentar una apariencia cada vez más similar a la de comunicaciones legítimas.

Por lo tanto, el problema consiste en determinar si es posible identificar automáticamente correos electrónicos potencialmente maliciosos mediante el análisis de sus características. Para ello, se propone desarrollar un sistema basado en técnicas de Inteligencia Artificial capaz de aprender patrones a partir de correos previamente clasificados y utilizar este conocimiento para determinar si un nuevo mensaje presenta características asociadas con un correo legítimo o potencialmente malicioso.

Justificación

El desarrollo de un sistema inteligente para la detección de correos maliciosos representa una aplicación práctica de la Inteligencia Artificial a un problema cotidiano relacionado con la seguridad informática. Cualquier persona que utilice correo electrónico puede estar expuesta a mensajes fraudulentos y, aunque los servicios actuales cuentan con mecanismos de protección, estudiar este problema permite

comprender cómo la IA puede utilizarse para identificar patrones que serían difíciles de representar únicamente mediante reglas fijas.

El proyecto también resulta viable dentro del contexto académico, ya que no requiere infraestructura especializada ni grandes cantidades de hardware. Puede desarrollarse principalmente mediante software utilizando un conjunto de datos de correos previamente etiquetados como legítimos o maliciosos. A partir de estos datos será posible entrenar y evaluar diferentes algoritmos de clasificación.

Su realización permitirá aplicar conceptos de Inteligencia Artificial y aprendizaje automático vistos durante la materia, incluyendo preparación de datos, extracción de características, entrenamiento de modelos, clasificación y evaluación de resultados. Además de obtener un sistema funcional, el proyecto permitirá analizar las ventajas y limitaciones de utilizar técnicas de IA para resolver un problema real.

Hipótesis

La aplicación de técnicas de Inteligencia Artificial mediante un modelo de clasificación supervisada permitirá identificar patrones presentes en el contenido y las características de los correos electrónicos, haciendo posible distinguir entre mensajes legítimos y potencialmente maliciosos con un nivel de precisión suficiente para demostrar la utilidad de estas técnicas como apoyo en la detección de amenazas.

El modelo podrá considerar características como las palabras utilizadas en el asunto y cuerpo del mensaje, presencia y cantidad de enlaces, términos relacionados con urgencia, solicitudes de información, características del remitente y otros elementos que puedan aportar información para realizar la clasificación.

Objetivo general

Desarrollar un sistema basado en técnicas de Inteligencia Artificial capaz de analizar las características de un correo electrónico y clasificarlo como legítimo o potencialmente malicioso, con la finalidad de demostrar la aplicación del aprendizaje automático en la identificación de amenazas transmitidas mediante correo electrónico.

Objetivos específicos

1. Obtener y preparar un conjunto de datos que contenga ejemplos de correos electrónicos legítimos y maliciosos previamente clasificados.
2. Identificar las características del correo que puedan ser relevantes para diferenciar mensajes legítimos de potencialmente maliciosos.

1. Análisis inicial de lenguaje y tecnología

Se realizará un estudio preliminar de los lenguajes de programación y tecnologías disponibles

para implementar el sistema. Se evaluarán opciones como Python, por su amplia biblioteca de herramientas de aprendizaje automático (scikit-learn, TensorFlow, PyTorch), así como frameworks que permitan el manejo eficiente de datos y la creación de interfaces. Este análisis permitirá seleccionar las herramientas más adecuadas en términos de facilidad de uso, soporte académico y viabilidad técnica.

3. Implementar y entrenar un modelo de clasificación supervisada utilizando los datos recopilados.
4. Evaluar el funcionamiento del modelo utilizando métricas como precisión, *precision*, *recall*, F1-score y matriz de confusión.
5. Desarrollar una interfaz sencilla que permita introducir o seleccionar un correo y visualizar la clasificación generada por el sistema.
6. Analizar los resultados obtenidos e identificar las principales limitaciones del modelo.

Metodología

El proyecto se desarrollará utilizando un enfoque experimental basado en aprendizaje automático supervisado. En una primera etapa se realizará la búsqueda y selección de un conjunto de datos que contenga correos electrónicos previamente etiquetados. Se buscará que existan suficientes ejemplos de las diferentes clases para poder realizar correctamente el entrenamiento y posteriormente comprobar el comportamiento del modelo con información que no haya utilizado durante dicho entrenamiento.

Posteriormente se realizará el preprocesamiento de los datos. En el caso del contenido textual se podrán eliminar elementos innecesarios, normalizar palabras y transformar el texto a una representación numérica mediante técnicas como **TF-IDF**, permitiendo que los algoritmos de aprendizaje automático puedan trabajar con el contenido del correo.

Además del texto, podrán extraerse características adicionales, como cantidad de enlaces, longitud del mensaje, determinadas palabras asociadas con urgencia o solicitudes de información y características disponibles del remitente. El alcance final dependerá de la información proporcionada por el conjunto de datos seleccionado.

Una vez preparados los datos, estos se dividirán en conjuntos de entrenamiento y prueba. El primero será utilizado para que el algoritmo encuentre patrones asociados con cada categoría, mientras que el segundo permitirá evaluar su comportamiento con ejemplos que el modelo no haya visto previamente.

Se podrán comparar algoritmos de clasificación como **Naive Bayes**, **Random Forest** y **Support Vector Machine (SVM)**. La comparación permitirá seleccionar el modelo que presente el mejor equilibrio entre los resultados obtenidos y la complejidad necesaria para su implementación.

Finalmente, el modelo seleccionado se integrará en una aplicación sencilla donde pueda proporcionarse el contenido de un correo para obtener una clasificación. El sistema mostrará si el mensaje se considera legítimo o potencialmente malicioso y, cuando el modelo utilizado lo permita, una puntuación o probabilidad asociada a la predicción.

Experimentación

La experimentación tendrá como objetivo comprobar si el modelo desarrollado puede clasificar correctamente correos que no hayan sido utilizados durante su entrenamiento. Para evitar evaluar al sistema con la misma información con la que aprendió, el conjunto de datos será separado en datos de entrenamiento y datos de prueba.

Se realizarán experimentos con diferentes algoritmos de clasificación utilizando las mismas condiciones y conjuntos de datos. Los resultados se compararán mediante métricas como **accuracy**, **precision**, **recall** y **F1-score**, además de utilizar una **matriz de confusión** para observar cuántos correos legítimos y maliciosos fueron clasificados correctamente y cuántos fueron confundidos.

Una consideración especialmente importante será analizar los **falsos negativos**, es decir, aquellos correos maliciosos que el sistema clasifique incorrectamente como legítimos, debido a que representan el error de mayor riesgo dentro del problema planteado. También se estudiarán los falsos positivos, donde un correo legítimo sea identificado incorrectamente como sospechoso.

Como prueba final se podrán introducir ejemplos de correos diferentes a los utilizados durante el entrenamiento y observar la respuesta del sistema. Esto permitirá determinar experimentalmente qué modelo ofrece mejores resultados y qué características tienen mayor utilidad para la clasificación.

Conclusiones

El proyecto propuesto permite aplicar técnicas de Inteligencia Artificial a un problema cotidiano y relevante como la recepción de correos electrónicos potencialmente maliciosos. Su desarrollo permitirá estudiar cómo un algoritmo puede aprender patrones a partir de ejemplos previamente clasificados y utilizar ese aprendizaje para realizar predicciones sobre nuevos mensajes.

Además, el proyecto es viable debido a que puede desarrollarse mediante herramientas de software y conjuntos de datos existentes, sin requerir infraestructura

especializada. La comparación entre diferentes algoritmos permitirá determinar experimentalmente cuál resulta más adecuado para el problema.